



UNIVERSITE DE MONTPELLIER

Faculté des Sciences — Master Statistique et Science des Données

Algorithmes de Bandits Adaptatifs pour les Méga-études

Implémentation, Simulation et Application Empirique

Projet de Recherche

Étudiants :

Ines BAHRAOUI Chams-Eddine BOUAZIZ Marouane DAOUDI

`ines.bahraoui@etu.umontpellier.fr` `chams-eddine.bouaziz@etu.umontpellier.fr`

`marouane.daoudi@etu.umontpellier.fr`

Équipe encadrante :

Adrien NGUYEN-HUU (Enseignant-Chercheur) — `adrien.nguyen-huu@umontpellier.fr`

Luka BOISGIBAUT (Doctorant) — `luka.boisgibault@hotmail.com`

Année Universitaire 2025–2026

Table des matières

1	Contexte	2			
2	Cadre Théorique	2			
2.1	Contextualisation du problème	2	4.4.3	Analyse	15
2.2	Critères d'erreur et de puissance	3	4.5	Expérience 4 : Influence de l'initialisation (init_pulls)	15
2.3	Séquences de confiance : pourquoi et comment	4	4.5.1	Protocole	15
2.3.1	Normal Mixture Confidence Sequence (NM)	4	4.5.2	Résultats	15
2.3.2	Séquence de confiance par martingale de pari	5	4.5.3	Analyse	16
2.4	Contrôle dynamique du FDR : procédure BH anytime	7	4.6	Expérience 5 : Proportion de vrais positifs . .	16
2.5	Complexité échantillonnale et gain adaptatif .	7	4.6.1	Protocole	16
2.6	Règle d'échantillonnage adaptatif (UCB) . . .	8	4.6.2	Résultats	16
2.7	Variante SR : remplacer UCB par des rejets successifs	8	4.6.3	Analyse	16
2.8	Simulation sur données réelles : stratégie de rééchantillonnage	9	4.7	Synthèse des simulations	17
2.9	Préservation des garanties théoriques	9	5	Application Empirique	17
3	Algorithme et Implémentation	10	5.1	Comparaison des quatre algorithmes sur données simulées	17
3.1	Récapitulatif des cinq séquences de confiance .	10	5.1.1	Configuration expérimentale	17
3.2	Sélection UCB et procédure BH	11	5.1.2	Performance globale	17
3.3	Variante SR : sélection par rejets successifs . .	11	5.1.3	Ordre de détection des bras	18
4	Etude de Simulation	12	5.1.4	Concordance des ordres : τ de Kendall	19
4.1	Protocole expérimental	12	5.1.5	Robustesse temporelle	20
4.1.1	Environnement de simulation	12	5.1.6	Synthèse	20
4.1.2	Métriques d'évaluation	13	5.2	Résultat sur les données réelles	20
4.1.3	Configuration de base	13	5.2.1	Présentation et analyse des jeux de données réelles	20
4.2	Expérience 1 : Influence du niveau de confiance δ	13	5.2.2	Comparaison des quatre algorithmes .	21
4.2.1	Protocole	13	5.2.3	Comparaison des résultats des 4 algorithmes	21
4.2.2	Résultats	13	6	Discussion et Limites	25
4.2.3	Analyse	14	7	Conclusion	26
4.3	Expérience 2 : Influence du bruit σ	14	A	Annexe - Simulateur interactif	28
4.3.1	Protocole	14	B	Annexe - Expérience 1	28
4.3.2	Résultats	14	C	Annexe - Expérience 2	29
4.3.3	Analyse	14	D	Annexe - Expérience 3	30
4.4	Expérience 3 : Influence de l'écart entre bras (Δ)	15	E	Annexe - Expérience 4	31
4.4.1	Protocole	15	F	Annexe - Expérience 5	31
4.4.2	Résultats	15	G	Annexe - Statistiques classiques des jeux de données réelles	32
			H	Annexe - Résultats sur données réelles	36

1. Contexte

Le cadre classique de Neyman–Pearson formalise le test statistique comme un arbitrage entre deux risques : l’erreur de type I, qui consiste à rejeter à tort une hypothèse nulle, et l’erreur de type II, qui consiste à ne pas détecter un effet réel. Cette approche suppose généralement un protocole fixé à l’avance : la taille d’échantillon est déterminée avant l’expérience, les données sont collectées, puis les tests sont effectués une seule fois. Or, dans de nombreuses expériences modernes, notamment les tests A/B, les essais adaptatifs et les méga-études comportementales, les données arrivent progressivement et les décisions peuvent être prises en cours d’expérience. Regarder les résultats de manière répétée avec des p-values classiques invalide alors le contrôle de l’erreur : c’est le problème du monitoring séquentiel.

L’analyse séquentielle moderne généralise ce cadre en introduisant des outils d’inférence *always-valid*, c’est-à-dire valables à tout instant. Dans l’esprit des travaux sur l’inférence toujours valide, notamment l’article SAVE/SAVI sur le monitoring continu des tests A/B, une p-value anytime reste correcte même si l’expérimentateur observe les résultats plusieurs fois et décide d’arrêter l’expérience de façon adaptative. Cette propriété est centrale : elle permet de combiner apprentissage séquentiel, arrêt anticipé et contrôle statistique sans tomber dans le p-hacking.

Dans ce contexte, Jamieson et Jain (JJ) proposent une contribution nouvelle : reformuler le problème des tests multiples comme un problème de bandits multi-bras avec contrôle du taux de fausses découvertes. Leur algorithme ne se contente pas de tester uniformément tous les traitements ; il alloue adaptativement les observations vers les bras les plus prometteurs ou les plus incertains, tout en appliquant une procédure de Benjamini–Hochberg à des p-values anytime. La nouveauté de JJ est donc de lier trois éléments habituellement séparés : exploration adaptative, tests multiples et validité séquentielle des p-values.

L’objectif de ce travail est d’étudier ce cadre dans une perspective appliquée. Nous implémentons l’algorithme de Jamieson et Jain, comparons plusieurs séquences de confiance et variantes de p-values anytime, puis évaluons leurs performances par simulation en termes de puissance, de vitesse de détection et de contrôle du FDR. Enfin, nous cherchons à appliquer cette méthodologie à des méga-études réelles issues de données comportementales et de vaccination, afin de déterminer dans quelle mesure l’approche adaptative de JJ peut réduire le coût expérimental tout en préservant des garanties statistiques fiables.

2. Cadre Théorique

2.1. Contextualisation du problème

On se place dans le cadre d’un **bandit multi-bras** : n traitements sont indexés par $i \in [n] = \{1, \dots, n\}$, chacun associé à une distribution ν_i de moyenne μ_i inconnue. À chaque instant t , l’agent choisit un traitement i_t , observe une récompense $X_{i_t, t} \sim \nu_{i_t}$ indépendante du passé, et met à jour ses statistiques. Selon les données, ν_i suit une loi de Bernoulli (données binaires : taux de succès, de conversion) ou une loi sub-gaussienne (données continues : mesures quantitatives).

L’objectif n’est pas de maximiser les gains, mais d’identifier aussi rapidement que possible les traitements *significativement efficaces*, tout en maîtrisant le risque de fausse découverte. Pour chaque traitement i , on formule un test unilatéral contre un seuil μ_0 estimé à partir du bras contrôle :

	Hypothèse	Formulation	Interprétation
$H_0^{(i)}$	nulle	$\mu_i \leq \mu_0$	le traitement i n’est pas supérieur au contrôle
$H_1^{(i)}$	alternative	$\mu_i > \mu_0$	le traitement i est significativement efficace

Table 1 – Formulation du test unilatéral de chaque traitement i contre le seuil de référence μ_0 du bras contrôle.

où μ_0 désigne la référence du bras contrôle. Nous distinguons deux régimes d’opération :

— **Mode mono-échantillon** : On suppose μ_0 connue. On estime *une seule fois* à partir des observations de

contrôle collectées à partir des données, puis *figé* pour toute la suite. Le seuil est alors une constante indépendante des décisions futures et le cadre original de Jamieson & Jain [1] s'applique directement.

- **Mode bi-échantillon en ligne** : On suppose μ_0 inconnue. Le bras contrôle continue d'être tiré durant la phase adaptative et μ_0 est remplacé par une estimation séquentielle $\mu_{0,t}$ fondée sur la borne supérieure d'une séquence de confiance *anytime* sur μ_c . Le seuil devient aléatoire et $\mathcal{F}_{t-1}$ -mesurable, ce qui nécessite une correction dédiée discutée à la Section 2 (« Préservation des garanties »).

L'algorithme produit un ensemble de découvertes $S_t \subseteq [n]$ croissant au fil du temps. On note H_1 l'ensemble des traitements réellement supérieurs ($H_1^{(i)}$ vraie), H_0 le complémentaire, et $\Delta = \min_{i \in H_1} (\mu_i - \mu_0)$ la plus petite séparation pertinente.

2.2. Critères d'erreur et de puissance

Tester simultanément n traitements pose un problème fondamental : même si chaque test individuel est validé au niveau δ , le nombre d'erreurs commises quelque part croît avec n . Si l'on applique naïvement un seuil δ à chacun des n tests, le risque global d'erreur devient approximativement $n\delta$, ce qui est inacceptable dès que n est grand. Deux critères complémentaires permettent de formaliser ce qu'on cherche à garantir.

Définition 2.1: FDR et TPR — Benjamini & Hochberg [2]

Soient $\delta \in]0, 1[$, S_t l'ensemble des découvertes à l'instant t , H_1 l'ensemble des bras réellement efficaces ($H_1^{(i)}$ vraie) et H_0 son complémentaire.

Taux de fausses découvertes (FDR). On appelle fausse découverte un bras déclaré efficace alors qu'il ne l'est pas ($S_t \cap H_0$). Le FDR est la proportion espérée de telles erreurs parmi toutes les découvertes :

$$\text{FDR}(t) = \mathbb{E} \left[\frac{|S_t \cap H_0|}{|S_t| \vee 1} \right] \leq \delta \quad \forall t.$$

Le dénominateur $|S_t| \vee 1 = \max(|S_t|, 1)$ évite la division par zéro lorsqu'aucune découverte n'a été faite. Contrôler le FDR au niveau $\delta = 0,05$ signifie qu'en espérance, au plus 5% des traitements déclarés efficaces sont de fausses alarmes. Contrairement à une approche qui exigerait zéro erreur, le FDR tolère un petit nombre de faux positifs, ce qui est raisonnable en pratique et préserve la puissance de détection lorsque n est grand.

Taux de vrais positifs (TPR). Le TPR mesure la capacité de l'algorithme à ne pas manquer les traitements réellement efficaces : c'est la proportion de vrais positifs effectivement détectés,

$$\text{TPR}(t) = \mathbb{E} \left[\frac{|S_t \cap H_1|}{|H_1|} \right] \geq 1 - \delta \quad \forall t \geq \tau.$$

On vise TPR- δ après un horizon τ : passé ce temps, l'algorithme doit avoir détecté au moins une fraction $1 - \delta$ des bras vraiment efficaces. Un TPR faible signifie que beaucoup de bons traitements sont ignorés, c'est le coût d'une procédure trop conservative.

Le compromis FDR / TPR

Ces deux critères sont naturellement antagonistes. Abaisser le seuil de décision réduit les fausses alarmes (FDR $\downarrow$) mais augmente les omissions (TPR $\downarrow$), et réciproquement. L'objectif de l'algorithme est de contrôler strictement le FDR tout en maximisant le TPR, ce qui correspond à trouver le plus grand nombre de traitements efficaces sans dépasser le taux d'erreur autorisé. C'est le cadre formel de Jamieson & Jain [1].

2.3. Séquences de confiance : pourquoi et comment

Pourquoi pas un intervalle de confiance classique ?

Un intervalle de confiance classique est valide pour un horizon T fixé à l'avance : si l'on décide de regarder les données une seule fois au temps T , la couverture $1 - \delta$ est garantie. Mais dans notre cadre, l'algorithme consulte les données à *chaque* instant et peut prendre une décision à tout moment. Réutiliser le même test δ à chaque pas gonfle artificiellement le risque : c'est le problème du *p-hacking* séquentiel.

La solution est d'utiliser une **séquence de confiance** : un intervalle $[\hat{\mu}_i^t \pm \phi_t]$ valide *simultanément pour tout* $t \geq 1$ avec probabilité $1 - \delta$, sans inflation du risque.

Jamieson & Jain ne spécifient pas de CS particulier : ils posent l'existence d'un $\phi(t, \delta)$ générique vérifiant $\mathbb{P}(\forall t : |\hat{\mu}_{i,t} - \mu_i| \leq \phi(t, \delta)) \geq 1 - \delta$ et recommandent explicitement d'utiliser en pratique des bornes plus fines tenant compte de la variance empirique. Dans leurs expériences, ils emploient la borne de Howard et al. [3], Théorème 3 :

$$\phi_{\text{LIL}}(t, \delta) = \sqrt{\frac{2(\log(1/\delta) + 6 \log \log(1/\delta) + 3 \log \log(et/2))}{t}},$$

qui ne suppose pas σ^2 connu. Substituer naïvement $\hat{\sigma}^2$ dans une borne sous-gaussienne simple invaliderait la preuve théorique. Nous utilisons donc deux familles de séquences de confiance qui résolvent ce problème, présentées ci-dessous.

2.3.1. Normal Mixture Confidence Sequence (NM)

Définition 2.2: Normal Mixture CS — Howard et al. [3], Corollaire 1

Soit $\hat{V}_t$ la variance cumulée des observations (détaillée ci-dessous) et $\rho > 0$ un paramètre de réglage. La **Normal Mixture Confidence Sequence** est :

$$\phi_{\text{NM}}(t, \delta, \hat{V}_t, \rho) = \frac{1}{t} \sqrt{2(\hat{V}_t + \rho) \log \left(\frac{\sqrt{(\hat{V}_t + \rho)/\rho}}{\delta} \right)}$$

Pour tout bras i et tout $\delta \in (0, 1)$, cet intervalle est valide simultanément pour tout $t \geq 1$:

$$\mathbb{P}(\forall t \geq 1 : |\hat{\mu}_i^t - \mu_i| < \phi_{\text{NM}}(t, \delta, \hat{V}_t, \rho)) \geq 1 - \delta.$$

Accumulateur de variance $\hat{V}_t$. La quantité $\hat{V}_t$ mesure la dispersion cumulée des observations, mise à jour incrémentalement à chaque nouveau tirage selon la récurrence de Welford [4] :

$$\hat{V}_t = \hat{V}_{t-1} + (X_t - \bar{X}_{t-1})^2.$$

C'est l'accumulateur pour lequel la borne ϕ_{NM} est formellement garantie.

P-value anytime en forme fermée. L'inversion analytique de $\phi_{\text{NM}} = \bar{X}_t - \mu_0$ donne directement une p-value valide sans méthode numérique. En posant $d = \bar{X}_t - \mu_0 > 0$:

$$p_t^{\text{NM}} = \sqrt{\frac{\hat{V}_t + \rho}{\rho}} \exp \left(-\frac{d^2 \cdot t^2}{2(\hat{V}_t + \rho)} \right).$$

La p-value s'obtient en inversant $\phi_{\text{NM}}(t, p) = d$ en p . La méthode de Brent résout cette équation en au plus $\lceil \log_2((b-a)/\varepsilon) \rceil$ évaluations de ϕ_{NM} , où $[a, b] = [10^{-12}, 1 - 10^{-4}]$ est l'intervalle de recherche et $\varepsilon = 2 \times 10^{-12}$ la tolérance de `brentq`; cela donne au plus $\lceil \log_2(5 \times 10^{11}) \rceil = 39$ évaluations par bras. La forme fermée évalue p_t^{NM} directement en une seule opération arithmétique, réduisant le coût d'un facteur 39 par bras.

Auto-calibration de ρ

Rôle de ρ . Dans la formule de ϕ_{NM} , le terme $(\hat{V}_t + \rho)$ empêche l'intervalle de s'effondrer à zéro aux premiers instants (t petit, $\hat{V}_t \approx 0$). En pratique, ρ contrôle la largeur initiale de l'intervalle : trop petit, il laisse passer des fausses découvertes précoces ; trop grand, il ralentit la détection. La borne est valide pour *tout* $\rho > 0$ fixé [3], mais elle est la plus serrée lorsque ρ est proche de la variance réelle σ^2 des observations.

Pourquoi estimer ρ avec la médiane des variances empiriques ? La variance non biaisée de chaque bras i est estimée sur les n_i observations d'initialisation :

$$\hat{\sigma}_i^2 = \frac{\hat{V}_{n_i}}{n_i - 1}, \quad n_i \geq 2.$$

On pose alors

$$\hat{\rho} = \text{median}_{i: n_i \geq 2}(\hat{\sigma}_i^2).$$

La **médiane** (plutôt que la moyenne) est choisie pour sa robustesse aux bras ayant très peu d'observations ou une variance atypiquement élevée, qui gonfleraient la moyenne sans refléter le comportement typique des données.

Validité de la garantie. $\hat{\rho}$ est calculé *une seule fois*, à partir des données d'initialisation collectées avant le démarrage du processus adaptatif, puis figé pour toute la suite. ρ est donc une constante indépendante des décisions futures de l'algorithme, ce qui préserve intégralement la garantie anytime de ϕ_{NM} .

2.3.2. Séquence de confiance par martingale de pari

Principe du pari séquentiel

Imaginez un joueur qui parie sur l'issue de tirages successifs. S'il pense que la moyenne d'un bras est supérieure à μ_0 , il mise *dans ce sens* à chaque observation. Si l'hypothèse nulle est vraie, ses gains restent bornés en espérance ; si elle est fausse, sa richesse croît exponentiellement. L'inégalité de Ville garantit qu'une richesse élevée est une preuve statistiquement valide contre H_0 , à tout instant, sans paramètre de réglage.

Définition 2.3: Martingale de pari et p-value anytime (Waudby-Smith, I., & Ramdas, A. (2023) [12])

On initialise $M_0 = 1$. À chaque pas t , le parieur choisit une mise $\lambda_t \geq 0$ (calculée sur les observations passées), puis observe X_t ; la richesse est mise à jour de façon multiplicative. Par l'inégalité de Ville [11], M_t est une sur-martingale sous H_0 :

$$\mathbb{P}(\exists t \geq 1 : M_t \geq 1/\alpha) \leq \alpha, \quad \text{d'où} \quad p_t^{\text{bet}} = \frac{1}{M_t} = e^{-\log M_t}.$$

La richesse M_t croît d'autant plus vite que H_0 est fausse ; la p-value décroît en conséquence.

Condition de prédictabilité

La validité de la martingale exige que la mise λ_t soit $\mathcal{F}_{t-1}$ -**mesurable** : elle ne peut dépendre que des observations *antérieures* à t . En pratique, λ_t est calculé à partir de la moyenne empirique $\bar{X}_{t-1}$ et de la variance accumulée $\hat{\sigma}_{t-1}^2$, tous deux connus avant d'observer X_t .

Pari Bernoulli (données binaires, $X_t \in \{0, 1\}$). Le pari adaptatif de Kelly [12] maximise le taux de croissance de M_t sous H_1 :

$$\lambda_t = \frac{\bar{X}_{t-1} - \mu_0}{\bar{X}_{t-1}(1 - \bar{X}_{t-1})}, \quad M_t = M_{t-1} \cdot (1 + \lambda_t(X_t - \mu_0)).$$

Pari sous-gaussien (données continues). Pour des données continues à variance finie (Waudby-Smith & Ramdas [12]) :

$$\lambda_t = \frac{\bar{X}_{t-1} - \mu_0}{\hat{\sigma}_{t-1}^2}, \quad \lambda_t \in \left[0, \frac{1}{2\hat{\sigma}_{t-1}}\right], \quad \log M_t = \log M_{t-1} + \lambda_t(X_t - \mu_0) - \frac{\lambda_t^2 \hat{\sigma}_{t-1}^2}{2}.$$

Extension au mode bi-échantillon en ligne. Lorsque μ_0 n'est pas connu *a priori* mais estimé séquentiellement à partir du bras contrôle, parier contre l'estimation ponctuelle $\hat{\mu}_{c,t-1}$ rompt la propriété de sur-martingale. En effet, sous $H_0^{(i)} : \mu_i \leq \mu_c$, le calcul direct donne

$$\mathbb{E}[1 + \lambda_t(X_{i,t} - \hat{\mu}_{c,t-1}) | \mathcal{F}_{t-1}] = 1 + \lambda_t(\mu_i - \hat{\mu}_{c,t-1}),$$

qui peut excéder 1 dès que $\hat{\mu}_{c,t-1} < \mu_i$, un événement de probabilité non négligeable dès lors que $\mu_i = \mu_c$ (frontière de H_0). La $\mathcal{F}_{t-1}$ -mesurabilité ne suffit donc pas : il faut que la cible utilisée *domine* μ_c presque sûrement.

La solution adoptée, que nous appelons par la suite *seuil dominé*, consiste à parier non pas contre $\hat{\mu}_{c,t-1}$ mais contre la borne supérieure de la séquence de confiance anytime sur μ_c :

$$U_c(t-1) = \hat{\mu}_{c,t-1} + \phi(n_{c,t-1}, \delta_c, \hat{V}_{c,t-1}), \quad \mu_{0,t} := U_c(t-1).$$

Sur l'événement de couverture $\Omega_c = \{\forall t : \mu_c \leq U_c(t)\}$, de probabilité $\geq 1 - \delta_c$, on a $\mu_{0,t} \geq \mu_c \geq \mu_i$ sous $H_0^{(i)}$, ce qui restaure

$$\mathbb{E}[1 + \lambda_t(X_{i,t} - \mu_{0,t}) | \mathcal{F}_{t-1}] = 1 + \lambda_t(\mu_i - \mu_{0,t}) \leq 1.$$

La propriété de sur-martingale tient ainsi conditionnellement à Ω_c et l'inégalité de Ville fournit alors une p-value valide au niveau $\delta_t + \delta_c$ par union bound, où δ_t est le niveau utilisé dans la BH sur les bras de traitement. En pratique nous fixons $\delta_c = \delta/5$ et $\delta_t = 4\delta/5$, ce qui préserve l'essentiel du budget de risque pour les découvertes tout en laissant une marge confortable au contrôle.

Portée de la garantie selon le type de pari

Le raisonnement précédent suppose que, conditionnellement à Ω_c et au passé, $1 + \lambda_t(X_{i,t} - \mu_{0,t})$ est borné par sa valeur sous H_0 uniformément en t . Cette domination est **exacte pour le pari Bernoulli** : $X_{i,t}, \mu_{0,t}, \lambda_t$ évoluent dans des intervalles bornés ($[0, 1]$, resp. $[0, 1/\mu_{0,t}]$), ce qui rend la martingale formellement valide. Elle est en revanche **seulement heuristique pour le pari sous-gaussien** : la mise $\lambda_t = (\bar{X}_{i,t-1} - \mu_{0,t})/\hat{\sigma}_{i,t-1}^2$ dépend de l'estimation $\hat{\sigma}_{i,t-1}^2$ de la variance, qui n'est pas une borne supérieure presque sûre sur σ_i^2 . La validité e-processus n'est donc pas garantie en finite-sample. Nous conservons cette variante en mode bi-échantillon comme algorithme *pratique*, sa robustesse devant être évaluée par simulation.

Synthèse des séquences de confiance disponibles

Méthode	Type de données	Paramètre	Mode mono-éch.	Mode bi-éch. en ligne
NM (ϕ_{NM})	continues / binaires	ρ auto-calibré	formelle	formelle (union $\delta/2$)
LIL (ϕ_{LIL})	continues (sous-gauss.)	aucun	formelle	formelle (union $\delta/2$)
Pari Bernoulli	binaires	aucun	formelle	formelle (seuil dominé U_c)
Pari sous-gaussien	continues	aucun	formelle	<i>heuristique</i> (plug-in $\hat{\sigma}^2$)

La règle d'allocation adaptative utilisée dans ce travail s'inspire du principe UCB (*Upper Confidence Bound*), classique dans la littérature des bandits. L'idée générale est d'associer à chaque bras une valeur optimiste, obtenue en ajoutant à sa moyenne empirique un terme d'incertitude. Dans le cas mono-échantillon, ce score peut s'écrire sous la forme

$$\text{UCB}_i(t) = \hat{\mu}_i(t) + \phi_i(t),$$

où $\hat{\mu}_i(t)$ est la moyenne empirique du bras i et $\phi_i(t)$ le rayon de confiance associé. Un bras peut donc avoir une UCB élevée soit parce que sa moyenne empirique est grande, soit parce qu'il reste encore fortement incertain. La sélection par UCB réalise ainsi un compromis entre exploitation des bras déjà prometteurs et exploration des bras encore mal estimés.

Dans le cadre bi-échantillon, où chaque traitement est comparé à un bras contrôle, le score optimiste porte

naturellement sur l'écart $\mu_i - \mu_c$. On utilise alors un score de la forme

$$\text{UCB}_i(t) = \hat{\mu}_i(t) - \hat{\mu}_c(t) + \phi_i(t) + \phi_c(t),$$

afin de tenir compte à la fois de l'incertitude sur le traitement et de l'incertitude sur le contrôle. Les bras déjà déclarés positifs dans l'ensemble S_t ne sont plus explorés, car l'objectif de l'algorithme est de concentrer le budget restant sur les bras dont le statut statistique n'est pas encore tranché.

Dans notre implémentation, le critère UCB repose uniquement sur la séquence de confiance *Normal Mixture* classique. En revanche, au sein de la procédure de Benjamini–Hochberg, quatre options de séquences de confiance sont proposées : LIL, NM, le pari Bernoulli et le pari sous-gaussien.

La séquence NM intervient donc à deux niveaux : d'une part dans le calcul du rayon ϕ_{NM} , qui pilote la sélection des bras via l'UCB, et d'autre part dans la procédure BH typiquement lorsque le nombre d'observations disponibles est faible.

A contrario, lorsque l'échantillon devient plus important, il est pertinent d'utiliser une séquence de confiance spécialisée selon la nature des données : le pari Bernoulli pour les résultats binaires, et le pari sous-gaussien pour les mesures continues. Ces deux variantes ne nécessitent aucun paramètre de calibration et offrent, en mono-échantillon, des garanties formelles directes. En mode bi-échantillon en ligne, le mécanisme de *seuil dominé* (Section précédente) restaure la validité formelle du pari Bernoulli, tandis que le pari sous-gaussien conserve un statut heuristique dû au plug-in de la variance empirique.

2.4. Contrôle dynamique du FDR : procédure BH anytime

BH dans un cadre séquentiel

La procédure de Benjamini-Hochberg [2] contrôle le FDR en triant les p-values et en appliquant un seuil adaptatif : le seuil accordé à chaque test dépend du nombre de tests qu'on souhaite valider. La clé ici est que nos p-values sont *anytime* : elles restent valides à tout instant t , si bien qu'on peut exécuter BH à chaque pas de temps sans inflation du risque.

À chaque instant t , on trie les p-values $(p_1^t, \dots, p_{n'}^t)$ par ordre croissant et on cherche le plus grand k^* tel que :

$$p_{(k^*)}^t \leq \frac{\delta \cdot k^*}{n'},$$

où $n' = n$ est le nombre de traitements testés. On pose alors $S_t \leftarrow S_t \cup \{i : p_i^t \leq p_{(k^*)}^t\}$, l'ensemble S_t est monotone croissant.

Ce seuil adaptatif est nettement moins conservateur que la correction de Bonferroni (δ/n fixe), et sa puissance croît avec k : plus il y a de traitements réellement efficaces, plus le critère se relâche prudemment.

Remarque 2.1: Niveau BH et garantie formelle

Le Théorème 1 de Jamieson & Jain [1] garantit formellement $\text{FDR} \leq O(\delta \log(1/\delta))$ lorsque BH est appliqué au niveau $\delta' = \delta/(6,4 \log(36/\delta))$. En pratique, nous appliquons BH directement au niveau δ , conformément à la recommandation des auteurs qui estiment ce facteur logarithmique artifact de preuve (les p-values tendent vers les vraies valeurs à mesure que t croît, et le FDR observé reste proche de δ).

2.5. Complexité échantillonnale et gain adaptatif

Le résultat théorique central quantifie l'avantage de l'allocation adaptative sur l'allocation uniforme.

Théorème 2.1: Complexité d'échantillonnage (Jamieson & Jain [1])

(Mode mono-échantillon, μ_0 connu.) Soit $k = |H_1|$, $\Delta = \min_{i \in H_1} (\mu_i - \mu_0)$. Pour garantir FDR- δ et TPR- δ (Théorème 2 de J&J), il existe T tel que pour tout $t \geq T$:

$$T \lesssim \min \left\{ n\Delta^{-2} \log \frac{\log \Delta^{-2}}{\delta}, \sum_{i \in H_0} \Delta_i^{-2} \log \frac{\log \Delta_i^{-2}}{\delta} + \sum_{i \in H_1} \Delta_i^{-2} \log \frac{n \log \Delta_i^{-2}}{\delta} \right\}.$$

L'échantillonnage uniforme requiert quant à lui au moins $n\Delta^{-2} \log(n/k)$ tirages (Théorème 7 [1]). Le rapport $\tau_{\text{uniforme}}/\tau_{\text{adaptatif}} \sim \log(n/k)$ résume l'avantage adaptatif.

Ce que ce résultat signifie concrètement

Le facteur $\log(n/k)$ est d'autant plus grand que n est élevé et k petit, exactement la situation des méga-études [10]. Par exemple, avec $n = 100$ traitements et $k = 1$ seul réellement efficace, l'approche adaptative est **4.6 fois plus efficace** que l'approche uniforme. Cela se traduit directement par une réduction du nombre de patients exposés à des traitements sous-optimaux.

2.6. Règle d'échantillonnage adaptatif (UCB)

Pour atteindre la complexité optimale du Théorème 2.1, l'algorithme concentre ses tirages sur les bras encore susceptibles d'être déclarés positifs, c'est-à-dire ceux dont la borne supérieure de confiance reste élevée. Cette borne combine à la fois la moyenne empirique du bras et son incertitude. Les bras déjà classés dans S_t ne sont plus explorés.

$$i_t = \arg \max_{i \notin S_t} \left[\hat{\mu}_i^{n_i} + \phi_{\text{NM}}(n_i, \delta, \hat{V}_{n_i}, \rho) \right].$$

Phase d'initialisation

Avant de démarrer le processus adaptatif, n_0 observations par bras sont collectées pour amorcer les statistiques, auto-calibrer ρ et effectuer un premier passage BH. Les observations du bras contrôle durant cette phase servent à estimer μ_0 , qui est ensuite figé pour toute la durée de l'algorithme.

2.7. Variante SR : remplacer UCB par des rejets successifs

L'algorithme de Jamieson & Jain est composé de deux blocs : une règle de sélection de bras (UCB) et une règle d'inférence (NM+BH). Nous testons une variante dans laquelle on remplace uniquement le bloc UCB par la stratégie des **Rejets Successifs** (Audibert, Bubeck & Munos, COLT 2010 [9]), en conservant l'inférence NM+BH identique.

Règle de sélection par rejets successifs. Avec K bras et un budget T , l'algorithme divise l'exploration en $K - 1$ phases. Dans chaque phase, les bras actifs sont tirés à tour de rôle (round-robin). À la fin de chaque phase, le bras ayant la plus faible moyenne empirique est **éliminé** :

$$i^* = \arg \min_{i \in \mathcal{A}_k} (\hat{\mu}_i - \mu_0).$$

Le calendrier des phases est fixé à l'avance :

$$n_k = \left\lceil \frac{T - K}{\log(K)(K + 1 - k)} \right\rceil, \quad \bar{\log}(K) = \frac{1}{2} + \sum_{j=2}^K \frac{1}{j},$$

où n_k est le nombre cumulé de tirages par bras actif à la fin de la phase k . Les phases tardives reçoivent plus de tirages : quand il reste peu de bras, chacun est mieux estimé avant d'être éliminé.

Différence avec UCB. Dans J&J, UCB concentre dynamiquement les tirages sur les bras les plus incertains. SR suit au contraire un calendrier fixe, sans s'adapter aux observations en cours de route. Garder la même inférence

NM+BH pour les deux variantes permet d'isoler l'effet pur de la règle de sélection sur le FDR et le TPR.

2.8. Simulation sur données réelles : stratégie de rééchantillonnage

Pour évaluer les performances de l'algorithme sur les jeux de données réels, chaque expérience est répétée N fois afin d'estimer la variabilité des résultats. Cela nécessite de disposer de N scénarios distincts à partir d'un même jeu de données fini. Deux mécanismes sont utilisés.

Mélange des données entre simulations. Avant chaque simulation, l'ordre des observations de chaque bras est mélangé aléatoirement. Ainsi, deux simulations voient les mêmes patients dans des ordres différents, ce qui reproduit l'aléa lié à l'ordre d'arrivée des participants sans nécessiter de nouvelles données.

Rééchantillonnage lorsque les données sont épuisées. Lorsque l'algorithme a consommé toutes les observations disponibles pour un bras (c'est-à-dire $T_i(t) > n_i$), les observations suivantes sont tirées **au hasard parmi les données déjà observées** de ce bras :

$$X_{i,t} \sim \text{Uniforme}(x_{i,1}, \dots, x_{i,n_i}) \quad \text{si } T_i(t) > n_i.$$

On tire donc avec remise dans l'échantillon existant du bras, ce qui revient à supposer que les nouvelles observations suivent la même distribution que les observations passées. Ce mécanisme permet à l'algorithme de fonctionner sur un horizon $T > n_i$ sans introduire d'hypothèse sur la forme de la loi des données.

2.9. Préservation des garanties théoriques

Le Théorème 1 de Jamieson & Jain [1] établit que la procédure BH appliquée à des p-valeurs anytime contrôle le FDR à niveau $O(\alpha \log(1/\alpha))$ dès lors que : (i) les p-valeurs nulles $\{p_t^k\}_{k \in H_0}$ sont *sub-uniformes*, au sens où $\mathbb{P}(\exists t : p_t^k \leq x) \leq x$, et (ii) les p-valeurs nulles sont indépendantes entre bras. Le cadre original suppose également que μ_0 est connu et fixe. Les modifications que nous introduisons doivent donc être évaluées selon deux critères distincts : la validité anytime des p-valeurs individuelles et la structure de dépendance entre bras.

CS Normal Mixture. La CS Normal Mixture fondée sur la statistique de variance prévue par la borne fournit des p-valeurs anytime sub-uniformes sous H_0^k , et s'inscrit donc directement dans la condition (i) du Théorème 1.

Paris de Kelly / betting. La procédure de pari séquentiel produit une martingale de richesse valide lorsque la mise λ_t est $\mathcal{F}_{t-1}$ -mesurable et que le facteur de richesse $1 + \lambda_t(X_t - \mu_{0,t})$ « domine » sa contrepartie sous H_0 , au sens où la cible $\mu_{0,t}$ majore μ_i presque sûrement sur l'événement de validité. Par l'inégalité de Ville, $p_t^k = 1/M_t^k$ est alors une p-valeur anytime sub-uniforme. La nature de cette justification dépend du régime opérationnel et du type de pari, détaillés dans les paragraphes qui suivent.

Mode mono-échantillon avec μ_0 fixe. Notre implémentation teste chaque bras i contre un seuil μ_0 fixé à partir des observations du bras contrôle. Comme μ_0 est une constante indépendante des décisions futures, les e-processes de chaque bras sont indépendants entre eux et les p-valeurs $p_t^k = 1/M_t^k$ sont sub-uniformes sous H_0^k , aussi bien pour le pari Bernoulli que pour le pari sous-gaussien (la variance proxy reste alors borneable en pratique sur les jeux de données considérés). Les deux conditions du Théorème 1 sont satisfaites, et la procédure BH contrôle le FDR directement sans correction supplémentaire.

Mode bi-échantillon en ligne, pari Bernoulli (seuil dominé). Lorsque μ_0 est estimé séquentiellement, la mise λ_t devient $\mathcal{F}_{t-1}$ -mesurable mais ce n'est pas suffisant : il faut en outre que la cible domine μ_c presque sûrement. Nous substituons donc à $\hat{\mu}_{c,t-1}$ la borne supérieure de la séquence de confiance anytime sur μ_c ,

$$\mu_{0,t} = U_c(t-1) = \hat{\mu}_{c,t-1} + \phi(n_{c,t-1}, \delta_c, \hat{V}_{c,t-1}),$$

avec $\delta_c = \delta/5$. Sur l'événement de couverture $\Omega_c = \{\forall t : \mu_c \leq U_c(t)\}$, de probabilité $\geq 1 - \delta_c$, on a $\mu_{0,t} \geq \mu_c \geq \mu_i$ sous $H_0^{(i)}$, et la propriété de sur-martingale tient conditionnellement. Comme les facteurs $1 + \lambda_t(X_{i,t} - \mu_{0,t})$ restent bornés (observations dans $[0, 1]$ et $\lambda_t \in [0, 1/\mu_{0,t}]$), l'application de l'inégalité de Ville fournit alors des p-valeurs $p_t^k = 1/M_t^k$

anytime sub-uniformes, au prix d'un union bound léger $\delta = \delta_c + \delta_t$ avec $\delta_t = 4\delta/5$ utilisé dans BH. La garantie est ainsi formellement préservée pour les données binaires.

Mode bi-échantillon en ligne, pari sous-gaussien (statut heuristique). Pour les données continues, le même mécanisme de seuil dominé restaure la propriété de domination $\mu_{0,t} \geq \mu_c$, mais la mise

$$\lambda_t = \frac{\bar{X}_{i,t-1} - \mu_{0,t}}{\hat{\sigma}_{i,t-1}^2}$$

fait intervenir l'estimation $\hat{\sigma}_{i,t-1}^2$ de la variance, qui n'est pas une borne supérieure presque sûre sur σ_i^2 . L'argument sous-gaussien GROW de Waudby-Smith & Ramdas [12] suppose une variance proxy connue ou dominante ; le plug-in empirique invalide formellement l'argument martingale. Nous conservons néanmoins cette variante en tant qu'**algorithme pratique / heuristique** : ses performances empiriques (FDR, TPR) sont évaluées par simulation à la Section 4, mais aucune garantie finite-sample anytime n'est fournie en mode bi-échantillon en ligne. Cette limite est inhérente à la combinaison « pari sous-gaussien + variance estimée + contrôle online » et constitue une frontière ouverte de notre étude.

3. Algorithme et Implémentation

Les cinq séquences de confiance retenues (LIL d'origine, LIL heuristique, NM, pari Bernoulli, pari sous-gaussien) s'insèrent dans une même structure algorithmique : à chaque pas, on tire le bras maximisant un critère UCB, on met à jour les statistiques internes (variance cumulée $\hat{V}_t$ pour NM et LIL heuristique, log-martingale $\log M_t$ pour les paris), puis on calcule une p-value anytime soumise à la procédure BH. *Seul le rayon ϕ et la formule de p-value changent d'une CS à l'autre* ; la boucle principale reste identique. Nous regroupons donc les composantes propres à chaque CS dans un unique récapitulatif (Tableau 2), puis nous décrivons la boucle commune (Alg. 1).

3.1. Récapitulatif des cinq séquences de confiance

Le Tableau 2 précise, pour chacune des cinq CS, la statistique mise à jour incrémentalement à chaque observation et le rayon de confiance ou la p-value anytime associés. La cible $\mu_{0,t}$ désigne μ_0 en mode mono-échantillon et le seuil dominé $U_c(t-1) = \bar{\mu}_{c,t-1} + \phi_{\text{NM}}(n_{c,t-1}, \delta_c, \hat{V}_{c,t-1})$ en mode bi-échantillon en ligne (cf. Section 2). La mise λ_t est calculée à partir des statistiques du pas précédent, garantissant la $\mathcal{F}_{t-1}$ -mesurabilité.

Méthode	Statistique mise à jour	Rayon $\phi(t, \delta, \cdot)$ ou p-value
LIL d'origine	<i>aucune</i> (rayon sans accumulateur)	$\phi_{\text{LIL}} = \sqrt{\frac{2(\log(1/\delta) + 6\log\log(1/\delta) + 3\log\log(et/2))}{t}}$
LIL heuristique	$\hat{V}_t \leftarrow \hat{V}_{t-1} + (X_t - \bar{X}_{t-1})^2$, puis $\hat{\sigma}_t = \sqrt{\hat{V}_t/(t-1)}$	$\phi_{\text{LIL,h}} = \hat{\sigma}_t \cdot \phi_{\text{LIL}}$ (plug-in empirique de σ ; garantie formelle perdue).
NM	$\hat{V}_t \leftarrow \hat{V}_{t-1} + (X_t - \bar{X}_{t-1})^2$	$\phi_{\text{NM}} = \frac{1}{t} \sqrt{2(\hat{V}_t + \rho) \log\left(\frac{\sqrt{(\hat{V}_t + \rho)/\rho}}{\delta}\right)}$ p-value en forme fermée par inversion.
Pari Bernoulli	$\log M_t \leftarrow \log M_{t-1} + \log(1 + \lambda_t(X_t - \mu_{0,t}))$ avec $\lambda_t = \frac{\bar{X}_{t-1} - \mu_{0,t}}{\bar{X}_{t-1}(1 - \bar{X}_{t-1})} \in [0, 1/\mu_{0,t}]$	$p_t = e^{-\log M_t}$ (inégalité de Ville).
Pari sous-gaussien	$\log M_t \leftarrow \log M_{t-1} + \lambda_t(X_t - \mu_{0,t}) - \frac{1}{2}\lambda_t^2\hat{\sigma}_{t-1}^2$ avec $\lambda_t = \frac{\bar{X}_{t-1} - \mu_{0,t}}{\hat{\sigma}_{t-1}^2} \in [0, 1/(2\hat{\sigma}_{t-1})]$	$p_t = e^{-\log M_t}$ (inégalité de Ville).

Table 2 – Récapitulatif des cinq séquences de confiance utilisées. La cible $\mu_{0,t}$ est constante (μ_0) en mode mono-échantillon et remplacée par $U_c(t-1)$ en mode bi-échantillon en ligne.

3.2. Sélection UCB et procédure BH

L'Algorithme 1 décrit la boucle principale : à chaque pas t , on sélectionne le bras par UCB, on tire une observation, on met à jour les statistiques internes selon la CS choisie (Tableau 2), puis on applique BH pour détecter les bras significatifs.

Algorithme 1 Boucle principale — UCB adaptatif et BH anytime

Entrée : n bras, seuil μ_0 , niveau δ , bras contrôle c (ou AUCUN), CS choisie parmi {LIL d'origine, LIL heuristique, NM, Pari Bernoulli, Pari sous-gaussien}

1: Tirer chaque bras une fois ; initialiser $\hat{\mu}_i, \hat{V}_i, n_i, \log M_i \leftarrow 0, S_t \leftarrow \emptyset$

2: Calibrer $\rho \leftarrow \text{médiane}_i(\hat{V}_i/(n_i - 1))$ // utile pour ϕ_{NM}

3: **for** $t = n + 1, n + 2, \dots$ **do**

4: // — Sélection UCB (rayon ϕ_{NM}) —

5: candidats $\leftarrow \{i \in [n] : i \notin S_t\}$ (bras contrôle toujours inclus si bi-échantillon)

6: **if** mono-échantillon **then**

7: $I_t \leftarrow \arg \max_{i \in \text{candidats}} \hat{\mu}_i + \phi_{\text{NM}}(n_i, \delta, \hat{V}_i)$

8: **else** (bi-échantillon, niveaux δ_t, δ_c avec $\delta_t + \delta_c \leq \delta$)

9: $I_t \leftarrow \arg \max_{i \in \text{candidats} \setminus \{c\}} (\hat{\mu}_i - \hat{\mu}_c) + \phi_{\text{NM}}(n_i, \delta_t, \hat{V}_i) + \phi_{\text{NM}}(n_c, \delta_c, \hat{V}_c)$

10: **end if**

11: Tirer le bras I_t ; obtenir observation X_t

12: Mettre à jour les statistiques de I_t selon la CS choisie (Tableau 2)

13: // — BH anytime —

14: $m \leftarrow |\text{candidats} \setminus \{c\}|$ (bras en test, contrôle exclu)

15: Calculer p_i pour tout $i \notin S_t, i \neq c$ (Tableau 2)

16: Trier : $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$

17: $k^* \leftarrow \max\{k : p_{(k)} \leq \delta \cdot k/m\}$

18: $S_t \leftarrow S_t \cup \{\text{bras de rang } 1 \text{ à } k^*\}$ // monotone croissant

19: **if** candidats $\setminus \{c\} = \emptyset$ **then**

20: **arrêter**

21: **end if**

22: **end for**

Sortie : ensemble S_t contrôlant le FDR au niveau δ à tout instant

3.3. Variante SR : sélection par rejets successifs

L'Algorithme 2 décrit la variante *Successive Rejects* (Audibert, Bubeck & Munos [9]) qui remplace la règle UCB par un calendrier d'élimination à phases. La procédure BH et le calcul des p-values restent identiques (Tableau 2) : seule la règle de sélection des bras change. L'ensemble actif $\mathcal{A}_k \subseteq [n] \setminus \{c\}$ est initialisé à tous les bras de traitement et réduit d'un élément à chaque fin de phase (le bras de plus petite moyenne empirique). Le calendrier des phases est fixé à l'avance par

$$n_k = \left\lceil \frac{T - K}{\log(K)(K + 1 - k)} \right\rceil, \quad \bar{\log}(K) = \frac{1}{2} + \sum_{j=2}^K \frac{1}{j},$$

où $K = |\mathcal{A}_0|$ est le nombre de bras initialement candidats et n_k le nombre cumulé de tirages par bras actif à la fin de la phase k .

Algorithme 2 Variante SR — règle de sélection par rejets successifs**Entrée :** n bras, bras contrôle c (ou AUCUN), budget T

- 1: // — *Initialisation supplémentaire propre à SR* —
- 2: $\mathcal{A} \leftarrow [n] \setminus \{c\}$; $K \leftarrow |\mathcal{A}|$; $k \leftarrow 0$
- 3: Calculer le calendrier $(n_1, \dots, n_{K-1})$ via la formule SR ci-dessus
- 4: // — *Remplace le bloc « Sélection UCB » de l'Alg. 1* —
- 5: $I_t \leftarrow$ prochain bras de $\mathcal{A} \setminus S_t$ en round-robin
- 6: // — *Élimination en fin de phase (insérée après la mise à jour des stats)* —
- 7: **if** $k+1 < K$ **et** $|\mathcal{A}| > 1$ **et** $n_i \geq n_{k+1} \forall i \in \mathcal{A}$ **then**
- 8: $i^* \leftarrow \arg \min_{i \in \mathcal{A}} (\hat{\mu}_i - \mu_0^{\text{ref}})$, $\mathcal{A} \leftarrow \mathcal{A} \setminus \{i^*\}$, $k \leftarrow k+1$
- 9: **end if**
- 10: // — *Le bloc « BH anytime » de l'Alg. 1 reste strictement identique* —

UCB ou SR : comparaison des deux règles de sélection

La procédure d'inférence (mise à jour des statistiques, calcul des p-values anytime, BH au niveau δ) est strictement identique entre les deux algorithmes ; seule la *règle d'allocation* diffère. UCB concentre dynamiquement les tirages sur les bras les plus incertains, tandis que SR suit un calendrier d'élimination fixé à l'avance. Comparer les deux variantes permet donc d'isoler l'effet pur de la stratégie d'échantillonnage sur le FDR et le TPR observés.

Rôle	JJ = Algorithme d'origine	V2 = NM	V3 = Betting	SR = Successive Reject
Exploration	UCB avec LIL	UCB avec Normal Mixture	UCB avec Normal Mixture	Phases d'exploration puis élimination
Décision	BH avec LIL	BH avec Normal Mixture	E-process betting	Rejet des bras non retenus / sélection finale

Table 3 – Comparaison des méthodes selon leur rôle dans l'algorithme

Ainsi les 4 grands types d'algorithmes testés et leurs différences sont présentés dans le tableau 2. D'abord l'algorithme nommé JJ correspond à notre version la plus proche possible du travail de Jamieson & Jain avec les quelques adaptations apportées dans le cas du seuil du contrôle inconnu. Puis, l'algorithme nommé V2 correspond à une adaptation de JJ avec des sequences de confiance de type normal-mixture, l'algorithme V3 est aussi une adaptation de JJ qui dispose d'une méthode de betting pour sa phase de décision et enfin SR est un algorithme totalement différent utilisé pour comparer les résultats de tous les algorithmes de JJ que ce soit JJ, V2 ou V3.

4. Etude de Simulation

Cette section présente une étude empirique par simulation visant à vérifier les garanties théoriques établies dans la Section 2 et à quantifier l'avantage pratique de l'allocation adaptative sur l'allocation uniforme dans différentes conditions expérimentales.

4.1. Protocole expérimental

4.1.1. Environnement de simulation

Les simulations ont été conduites en Python à l'aide d'un simulateur interactif développé pour l'occasion (Voir Annexe). Chaque bras i génère des récompenses $X_{i,t} \sim \mathcal{N}(\mu_i, \sigma^2)$.

Sauf mention contraire, toutes les expériences de cette section utilisent la séquence de confiance ϕ_{LIL} (Section 2.3),

conformément aux expériences originales de Jamieson & Jain. La comparaison avec NM et le pari sous-gaussien est traitée séparément en Section 5.3.

4.1.2. Métriques d'évaluation

Nous mesurons deux quantités principales :

- Le **TPR moyen** à l'instant t : $\bar{\rho}(t)$ est l'estimateur empirique sur N simulations de la quantité $\mathbb{E}[|S_t \cap H_1|/|H_1|]$ introduite à la Définition 2.2.
- Le **temps au TPR 90%**, noté $\tau_{0.9}$, défini comme le premier instant t tel que $\bar{\rho}(t) \geq 0.9$. **gain** d'un algorithme sur l'autre est le rapport relatif $1 - \tau_{0.9}^{\text{adapt}}/\tau_{0.9}^{\text{unif}}$. Cette métrique résume la vitesse en un scalaire interprétable (un gain de 50 % signifie « budget divisé par deux »), mais elle est *indéfinie* lorsqu'un algorithme n'atteint jamais 90 % dans l'horizon imparti : les régimes difficiles (σ élevé, Δ faible) la rendent inexploitable.
- L'**aire sous la courbe TPR** (AUC), définie par $\text{AUC} = \frac{1}{T} \int_0^T \bar{\rho}(t) dt$, intègre toute la dynamique en un scalaire compris entre 0 et 1. Elle reste définie même quand $\tau_{0.9}$ sature, et valorise les algorithmes qui atteignent un bon TPR *tôt* plutôt que seulement à la fin. Elle sert ainsi de mesure de robustesse, complémentaire à $\tau_{0.9}$.

Enfin, pour rendre les expériences sur le bruit et l'écart entre bras directement comparables, nous reparamétrisons le rapport signal/bruit par le d de **Cohen**, $d = \Delta/\sigma$. Les seuils usuels ($d \approx 0,2$ effet faible, 0,5 moyen, 0,8 fort) fournissent une grille de lecture standard pour situer chaque régime expérimental.

4.1.3. Configuration de base

Le Tableau ci-dessous résume les paramètres utilisés par défaut dans la suite. Sauf mention contraire, chaque expérience modifie un seul de ces paramètres en gardant les autres fixés.

Paramètre	Valeur
Nombre de bras n	10
Bruit σ	0,5
Niveau de confiance δ	0,05
Horizon T	800
Simulations N	330
Initialisation	10 tirages par bras
Vrais positifs H_1	2 bras ($\mu = 0,50$) et 3 bras ($\mu = 0,35$)
Vrais Négatifs H_0	5 bras ($\mu = 0,00$)

Table 4 – Configuration de base des simulations : paramètres par défaut, modifiés un à un dans les expériences suivantes.

4.2. Expérience 1 : Influence du niveau de confiance δ

4.2.1. Protocole

Nous faisons varier $\delta \in \{0,01; 0,05; 0,10; 0,20\}$ en maintenant la configuration de bras standard.

4.2.2. Résultats

Table 5 – Temps pour atteindre 90 % de TPR et gain AUC en fonction de δ ($N = 330$ simulations).

δ	$\tau_{0.9}^{\text{Adapt.}}$	$\tau_{0.9}^{\text{Unif.}}$	Gain Adapt./Unif.	$\Delta\text{AUC Adapt.} - \text{Unif.}$
0,01	196	601	67,4 %	+0,238
0,05	147	484	69,6 %	+0,183
0,10	125	421	70,3 %	+0,155
0,20	90	312	71,2 %	+0,120

Voir Annexe B — Expérience 1

4.2.3. Analyse

On observe que plus δ est grand, plus les deux algorithmes détectent rapidement : $\tau_{0.9}$ passe de 196 à 90 pour l'Adaptatif et de 601 à 312 pour l'Uniforme quand δ passe de 0,01 à 0,20. Cela est cohérent avec la théorie : un δ plus grand signifie un seuil de décision plus souple, donc les bras sont validés plus tôt.

Ce qui est intéressant, c'est que le gain de l'Adaptatif sur l'Uniforme reste stable autour de 67–71 % quelle que soit la valeur de δ : changer δ accélère les deux algorithmes de la même façon, sans modifier leur hiérarchie.

En revanche, le ΔAUC diminue quand δ augmente (de +0,238 à +0,120). Cela s'explique simplement : quand δ est grand, les deux algorithmes trouvent les bras positifs très vite et la courbe TPR monte rapidement pour les deux ; il y a donc moins de différence cumulée entre eux sur l'ensemble de l'horizon.

Ainsi, le choix de δ devrait être un compromis entre vitesse et rigueur : un δ élevé accélère la détection mais autorise plus de fausses découvertes (FDR observé de 0,001 à $\delta = 0,01$ contre 0,008 à $\delta = 0,20$).

4.3. Expérience 2 : Influence du bruit σ

4.3.1. Protocole

Nous faisons varier $\sigma \in \{0,1; 0,5; 1,0; 2,0\}$ avec $\delta = 0,05$ fixe, ce qui correspond aux d de Cohen du Table 6.

Table 6 – Correspondance $\sigma \leftrightarrow d$ de Cohen ($\Delta = 0,5$).

σ	$d = \Delta/\sigma$	Régime
0,1	5,00	Trivial
0,5	1,00	Fort
1,0	0,50	Moyen
2,0	0,25	Faible

4.3.2. Résultats

Table 7 – Influence du bruit σ sur le temps au TPR 90%, le gain en TPR à budget fixe et le gain AUC ($N = 330$ simulations).

σ (d)	$\tau_{0.9}^{\text{Adapt.}}$	$\tau_{0.9}^{\text{Unif.}}$	Gain	ΔAUC
0,1 ($d=5,0$)	0	0	0	0
0,5 ($d=1,0$)	150	467	67,4%	+0,181
1,0 ($d=0,5$)	>800	>800	0,0%	+0,315
2,0 ($d=0,25$)	>800	>800	0,0%	+0,024

Voir Annexe C — Expérience 2

4.3.3. Analyse

Les résultats montrent clairement que le niveau de bruit σ a un impact majeur sur les performances des deux algorithmes.

À $\sigma = 0,1$ ($d = 5,0$), le signal est tellement fort que les deux algorithmes détectent tous les bras positifs dès les premiers tirages : $\tau_{0.9} = 0$ pour les deux, il n'y a rien à comparer.

À $\sigma = 0,5$ ($d = 1,0$), on est dans le régime le plus favorable : l'Adaptatif atteint 90% de TPR en 150 tirages contre 467 pour l'Uniforme, soit un gain de 67,4%. C'est ici que l'avantage de l'allocation adaptative est le plus visible.

À $\sigma = 1,0$ ($d = 0,5$) et $\sigma = 2,0$ ($d = 0,25$), aucun des deux algorithmes n'atteint 90% de TPR avant la fin de l'horizon : $\tau_{0.9}$ n'est plus calculable. C'est là que le ΔAUC devient indispensable. Pour $\sigma = 1,0$, il vaut +0,315 : l'Adaptatif accumule beaucoup plus de découvertes que l'Uniforme sur tout l'horizon, même si les deux échouent à dépasser le seuil de 90%. Pour $\sigma = 2,0$, le ΔAUC chute à +0,024 : le bruit est si élevé que même l'Adaptatif ne parvient presque pas à détecter les bras positifs, comme on le voit sur le graphe (d) où les deux courbes restent proches de zéro.

En résumé, l'avantage adaptatif n'existe que dans une plage de bruit intermédiaire : trop faible, les deux algorithmes sont équivalents ; trop élevé, les deux échouent.

4.4. Expérience 3 : Influence de l'écart entre bras (Δ)

4.4.1. Protocole

Nous testons quatre configurations en gardant la structure de la configuration de base ($n = 10$ bras, $k = 2$ positifs et 8 négatifs, $\sigma = 0,5$, $\delta = 0,05$, $T = 800$) et en faisant varier la moyenne μ des bras positifs. Les bras négatifs ont tous une moyenne $\mu = 0$. Comme tous les positifs partagent la même moyenne, $\Delta_{\min} = \Delta = \mu_{\text{positif}}$. Les configurations sont résumées dans le Tableau 8.

Table 8 – Configurations testées pour l'expérience sur Δ ($n = 10$, $\sigma = 0,5$).

Configuration	μ des positifs	Δ	$d = \Delta/\sigma$
Effet faible	0,20	0,20	0,4
Effet moyen-faible	0,30	0,30	0,6
Effet moyen-fort	0,40	0,40	0,8
Effet fort (baseline)	0,50	0,50	1,0

4.4.2. Résultats

Table 9 – Influence de l'écart Δ entre les bras positifs et négatifs ($n = 10$, $\sigma = 0,5$, $\delta = 0,05$, $N = 330$).

Δ (d)	$\tau_{0,9}^{\text{Adapt.}}$	$\tau_{0,9}^{\text{Unif.}}$	Gain Adapt./Unif.	ΔAUC
0,20 ($d=0,4$)	>800	>800	0,0 %	+0,174
0,30 ($d=0,6$)	>800	>800	0,0 %	+0,176
0,40 ($d=0,8$)	>800	>800	0,0 %	+0,093
0,50 ($d=1,0$)	>800	>800	0,0 %	+0,048

Voir Annexe D — Expérience 3

4.4.3. Analyse

Dans toutes les configurations, ni l'Adaptatif ni l'Uniforme n'atteignent 90% de TPR avant la fin de l'horizon $T = 800$: le gain en temps est indéfini partout, et c'est le ΔAUC qui permet de comparer les algorithmes.

Le ΔAUC suit un motif en cloche : il est maximal à $\Delta = 0,30$ ($d = 0,6$, $\Delta\text{AUC} = +0,176$) et décroît des deux côtés. À $\Delta = 0,20$ ($d = 0,4$), les deux algorithmes avancent lentement et l'écart reste modéré (+0,174). À $\Delta = 0,50$ ($d = 1,0$), les deux convergent plus vite, ce qui réduit la surface entre les courbes (+0,048).

Ce résultat rappelle celui de l'Expérience 2 : l'avantage adaptatif est maximal dans un régime de difficulté intermédiaire. Lorsque Δ est faible, les deux algorithmes peinent équitablement ; lorsque Δ est fort, les deux convergent rapidement et l'écart se resserre.

4.5. Expérience 4 : Influence de l'initialisation (`init_pulls`)

4.5.1. Protocole

Nous activons la phase d'initialisation de l'algorithme adaptatif uniquement, avec `init_pulls` $\in \{0; 10; 50; 100\}$ observations pré-données par bras, $\sigma = 0,5$, $\delta = 0,05$.

4.5.2. Résultats

Table 10 – Impact de (`init_pulls`) sur la vitesse de découverte

<code>init_pulls</code>	$\tau_{0,9}^{\text{adapt}}$	$\tau_{0,9}^{\text{unif}}$	Gain	ΔAUC
0	> 800	> 800	0%	+0.112
10	> 800	> 800	0%	+0.128
50	> 800	> 800	0%	+0.020
100	> 800	> 800	0%	+0.000

Voir Annexe E — Expérience 4

4.5.3. Analyse

Les résultats montrent que le nombre initial d'observations par bras (*init_pulls*) a une influence sur la vitesse de découverte, mais que cet effet reste relativement limité.

Lorsque peu d'observations sont disponibles au départ (*init_pulls* = 0 ou 10), l'algorithme adaptatif progresse plus rapidement que l'allocation uniforme. Cet avantage apparaît surtout au début des simulations : la méthode adaptative identifie plus vite les bras prometteurs et concentre davantage d'observations sur ceux-ci. Cela se traduit par une différence visible entre les courbes TPR et par un ΔAUC positif.

En revanche, lorsque *init_pulls* augmente (50 puis 100), les deux courbes deviennent de plus en plus proches. Avec davantage d'informations initiales, les estimations des moyennes sont déjà suffisamment stables pour que les deux stratégies prennent des décisions similaires. L'intérêt de l'allocation adaptative diminue donc progressivement.

Ainsi, *init_pulls* = 10 apparaît comme un bon point de fonctionnement : c'est la valeur qui maximise le ΔAUC tout en gardant un budget d'initialisation modeste (125% de l'horizon pour $n = 10$ bras). Au-delà, on paie un coût fixe en initialisation sans gagner en différentiel sur l'adaptatif.

4.6. Expérience 5 : Proportion de vrais positifs

4.6.1. Protocole

Nous fixons $n = 10$ bras et faisons varier la proportion de vrais positifs k/n avec $k \in \{1, 5, 9\}$. Les bras positifs ont une moyenne $\mu_i = 0,5$ et les bras négatifs $\mu_i = 0$, soit un écart constant $\Delta = 0,5$.

4.6.2. Résultats

Voir Annexe F — Expérience 5

4.6.3. Analyse

La proportion k/n de vrais positifs influence directement le facteur $\log(n/k)$ qui apparaît dans le Théorème 2.2. Quand k est petit (peu de bons bras à trouver parmi beaucoup), ce facteur logarithmique est grand : l'algorithme adaptatif tire le meilleur parti de la situation en identifiant rapidement les rares bons bras et en concentrant le budget restant sur eux.

C'est exactement ce qu'on observe sur la Figure 15. En configuration 1/9, le contraste est marqué : à $T = 800$, l'adaptatif plafonne autour de 0,7 de TPR contre $\approx 0,4$ pour l'uniforme. Plus la proportion de positifs augmente, plus les deux courbes se rapprochent : en 5/5, l'écart se réduit nettement, et en 9/1 les deux courbes sont quasi confondues et atteignent rapidement $TPR = 1$.

À noter un paradoxe apparent dans la lecture de ces courbes : trouver un seul bon bras parmi dix (1/9) est plus difficile à mesurer qu'en trouver neuf (9/1). Le TPR étant un taux, ne pas trouver l'unique vrai positif maintient la métrique à 0, ce qui rend la configuration 1/9 structurellement plus pénalisante. En 9/1, à l'inverse, chaque tirage a 90% de chances de tomber sur un bon bras, ce qui rend la découverte mécaniquement triviale, indépendamment de la stratégie d'allocation.

4.7. Synthèse des simulations

Paramètre	Effet sur le gain adaptatif	Recommandation
δ	Stable (67–71 %) sur toute la plage testée	Arbitrage vitesse / FDR
σ extrême	Effondré (U inversé)	Régime intermédiaire requis
Δ petit	Δ AUC en cloche, optimum à $\Delta = 0,30$	Augmenter T
init_pulls	Pic à 10 tirages, s'efface à 100	Compromis vers 10
k/n petit	Amplifié, conforme à $\log(n/k)$	Adaptatif crucial si $k \ll n$

Table 11 – Synthèse de l'influence des paramètres expérimentaux sur les performances comparées des deux algorithmes.

L'ensemble des expériences confirme le résultat théorique central de Jamieson & Jain [1] : l'avantage de l'algorithme adaptatif se manifeste pleinement dans le régime des signaux modérés et des positifs rares. Lorsque la tâche est trop facile (signal très fort, ou très peu de nuls), les deux algorithmes convergent rapidement et il n'y a rien à gagner ; lorsqu'elle est trop difficile (bruit massif, Δ très petit), les deux échouent ensemble. Entre les deux, l'allocation adaptative permet une réduction du budget expérimental de 67 à 71 % à TPR fixé, en accord qualitatif avec le facteur théorique $\log(n/k)$ qui caractérise le contexte typique des méga-études.

5. Application Empirique

5.1. Comparaison des quatre algorithmes sur données simulées

Avant de passer aux données réelles, nous comparons les quatre algorithmes sur une configuration de simulation plus exigeante que celle de la Section 4. Nous comparons **JJ** (LIL d'origine), **V2** (NM), **V3** (pari sous-gaussien) et **SR** (rejets successifs avec inférence NM-M2). Les quatre partagent la même procédure BH anytime au niveau $\delta = 0,05$: seules diffèrent la règle de sélection (UCB ou SR) et la séquence de confiance utilisée pour le calcul de la p -value.

Au-delà du TPR et du FDR finaux, nous avons voulu regarder *comment* les algorithmes diffèrent dans leur dynamique de découverte. Trois angles sont examinés en plus des indicateurs classiques : l'ordre dans lequel les bras sont détectés, la concordance entre algorithmes via le τ de Kendall, et la robustesse temporelle (écart inter-algorithmes des temps de première détection).

5.1.1. Configuration expérimentale

On simule $n = 12$ bras gaussiens $X_{i,t} \sim \mathcal{N}(\mu_i, \sigma^2)$ avec $\sigma = 0,5$ et un seuil $\mu_0 = 0$. Les moyennes sont choisies pour couvrir un large spectre de difficultés, du signal fort ($\mu = 0,50$) à des bras marginaux ($\mu = 0,05$) en passant par plusieurs nuls stricts. Le détail figure dans le Tableau 12.

Type	Bras	Moyenne μ_i	Cardinal
Positifs forts	0, 3	{0,50; 0,45}	2
Positifs moyens	1, 2	0,35	2
Positifs faibles	4, 7	{0,25; 0,20}	2
Positifs marginaux	5, 8	{0,05; 0,10}	2
Vrais nuls (H_0)	6, 9, 10, 11	0,00	4

Table 12 – Configuration à 12 bras. $|H_1| = 8$ bras à détecter, $|H_0| = 4$ vrais nuls. Paramètres communs : $\sigma = 0,5$, $\mu_0 = 0$, $\delta = 0,05$, $T = 800$, $N = 330$ simulations, 10 tirages d'initialisation par bras.

5.1.2. Performance globale

Le Tableau 13 donne les TPR et FDR moyens sur les 330 simulations, en mode Adaptive et Uniform. La Figure 1 montre les trajectoires correspondantes.

Algo.	TPR Adapt.	FDR Adapt.	TPR Unif.	Gain AUC
JJ	0,770	0,002	0,596	+0,222
V2	0,831	0,005	0,646	+0,241
V3	0,857	0,022	0,739	+0,152
SR	0,706	0,002	0,646	+0,043

Table 13 – TPR et FDR finaux par algorithme ($N = 330$ simulations, $T = 800$). Le contrôle $\text{FDR} \leq \delta = 0,05$ est respecté par les quatre.




Figure 1 – Vitesse de découverte des quatre algorithmes en modes Adaptative et Uniform.

V3 obtient le meilleur TPR (0,857) mais aussi le FDR le plus élevé (0,022). Cela reste sous δ , mais l'écart avec les autres ($\approx 0,002$ – $0,005$) montre que le pari sous-gaussien utilise une partie de sa marge pour aller plus vite. V2 offre le meilleur compromis : TPR de 0,831 pour un FDR de seulement 0,005. JJ est plus lent (0,770) mais avec le FDR le plus bas. SR est nettement en retrait sur le TPR (0,706) et son gain AUC par rapport à son baseline uniform est minime (+0,043 contre +0,15–+0,24 pour les variantes UCB) : son calendrier d'élimination fixe ne profite presque pas du retour d'information.

5.1.3. Ordre de détection des bras

Le TPR final ne dit rien sur *l'ordre* dans lequel les bras sont découverts. Or pour une méga-étude, cet ordre conditionne directement les décisions d'arrêt ou de financement.

L'ordre empirique $[0 \prec 3 \prec 1 \prec 2 \prec 4 \prec 7 \prec 8]$ suit fidèlement l'ordre théorique des moyennes (les bras 1 et 2 sont interchangeables car $\mu_1 = \mu_2 = 0,35$). Sur les bras forts (0 et 3), les quatre algorithmes détectent vite et se ressemblent (médianes ≤ 100). La différence se creuse à partir du bras 1 : V3 garde une médiane basse (~ 100) alors que SR monte déjà au-dessus de 200. Pour le bras 7 ($\mu = 0,20$), l'écart est marqué : V3 médiane ≈ 200 , JJ ≈ 380 , SR sature presque à T . Le bras 8 ($\mu = 0,10$) marque le point de bascule : seuls V2 et V3 le détectent dans une fraction notable des simulations, JJ et SR échouent dans la majorité. Pour les bras 5, 6, 9, 10, 11, on n'observe que des points aberrants, ce qui est cohérent avec le contrôle du FDR.

Pour mesurer la stabilité de cet ordre d'une simulation à l'autre, nous avons extrait pour chaque simulation la séquence ordonnée des bras découverts. Sur les $330 \times 4 = 1320$ exécutions, on dénombre 623 séquences distinctes. Le Tableau 2a liste les 10 séquences les plus fréquentes et la Figure 2b détaille leur répartition par algorithme.

Séq.	Pattern	Total
L1	[0, 3, 2, 1, 4, 7]	32
L2	[0, 1, 3, 2, 4, 7]	25
L3	[0, 3, 1, 2, 4, 7]	25
L4	[3, 0, 1, 2, 4, 7]	23
L5	[0, 2, 3, 1, 4, 7]	20
L6	[0, 3, 1, 2, 7, 4]	15
L7	[0, 1, 3, 4, 2, 7]	14
L8	[0, 3, 2, 1, 7, 4]	14
L9	[3, 0, 1, 2, 7, 4]	13
L10	[0, 3, 1, 2, 4]	13

(a) Légende des 10 séquences les plus fréquentes.


(b) Comptage par algorithme ($N = 330$ par algo).

Figure 2 — Séquences exactes de découverte (623 séquences distinctes sur $330 \times 4 = 1320$ exécutions). La séquence dominante L1 = [0, 3, 2, 1, 4, 7] correspond exactement à l'ordre théorique des μ_i (modulo l'inversion $1 \leftrightarrow 2$, indistinguables car $\mu_1 = \mu_2 = 0,35$).

Un résultat un peu contre-intuitif ressort ici : c'est **JJ** qui produit la séquence canonique **L1** le plus souvent (17 fois sur 330), alors que **V3** — pourtant le meilleur en TPR — ne la produit que 4 fois. À l'inverse, **V3** a la plus grande masse dans la colonne « Autres » (311 séquences distinctes). Autrement dit, **V3** trouve *plus* de bras mais dans un ordre *plus variable* d'une simulation à l'autre. Cela vient probablement du fait que la mise λ_t du pari amplifie tôt les écarts de richesse : la dynamique devient plus sensible à l'aléa des premières observations. **JJ**, qui est plus prudent, attend davantage de données avant de trancher et donne donc une trajectoire plus reproductible.

5.1.4. Concordance des ordres : τ de Kendall

Les séquences ci-dessus varient au sein d'une même méthode. On peut se demander si les méthodes *entre elles* produisent au moins le même classement global des bras. Pour chaque algorithme, nous calculons le rang moyen de première détection de chaque bras, puis nous mesurons la corrélation entre paires d'algorithmes via le τ de Kendall (Figure 3).




Figure 3 — Concordance des ordres de détection (rangs médians) entre les quatre algorithmes en mode Adaptive. Tous les coefficients sont significatifs à $p < 0,01$.

Tous les τ sont entre 0,94 et 1,00, et tous significatifs à $p < 0,01$. **V2** et **V3** ont même $\tau = 1,00$, ce qui est normal puisqu'ils partagent la règle de sélection UCB et ne diffèrent que par la p -value. Même chose pour **JJ** et **SR** ($\tau = 1,00$), les deux algorithmes les plus prudents.

Concrètement, cela veut dire que le choix d'algorithme joue sur la *vitesse* (combien d'observations pour atteindre tel TPR) et sur la marge de FDR, mais pas sur la *hiérarchie* des bras apprise. C'est un point important pour l'application aux données réelles : les premiers bras déclarés efficaces seront essentiellement les mêmes quel que soit l'algorithme.

5.1.5. Robustesse temporelle

Pour résumer visuellement l'écart entre algorithmes à *chaque niveau de difficulté*, on trace la médiane du temps de première détection par bras, et on rajoute l'étendue inter-algorithmes $\Delta = \max_{\text{algo}} - \min_{\text{algo}}$ (Figure 4). Un Δ petit indique que les algorithmes sont d'accord sur la vitesse, un Δ grand qu'ils divergent.




Figure 4 – Médiane du temps de première détection par bras pour chaque algorithme (Adaptive). La bande grise est l'étendue inter-algorithmes Δ .

Sur les bras forts (0 et 3), $\Delta \leq 110$: tous détectent vite, le choix de méthode importe peu. La bande grise s'élargit progressivement à mesure que μ diminue, et atteint un maximum de $\Delta = 524$ sur le bras 7 ($\mu = 0,20$). Au-delà, Δ retombe à zéro non pas parce que les algorithmes se rejoignent, mais parce qu'ils *saturent tous* à $T = 800$: le signal est trop faible pour l'horizon imparti.

Ce pic à $\Delta = 524$ est particulièrement parlant : c'est dans cette zone de signal moyen (d de Cohen $\approx 0,4$) que les différences entre séquences de confiance se traduisent en plusieurs *centaines* d'observations supplémentaires. Pour une méga-étude où chaque observation correspond à un participant, ce n'est pas négligeable.

5.1.6. Synthèse

Les expériences de cette section montrent que les méthodes adaptatives de type UCB (JJ, V2 et V3) sont nettement plus efficaces que l'allocation uniforme pour accélérer la découverte des bras positifs. À l'inverse, SR profite beaucoup moins du retour d'information, ce qui limite fortement son gain adaptatif.

Parmi les variantes testées, JJ apparaît comme la méthode la plus prudente : son FDR est très faible mais son TPR reste plus limité. V3 est la plus agressive, avec le meilleur TPR mais aussi le FDR le plus élevé, bien qu'il reste sous le seuil $\delta = 0.05$. V2 offre finalement le compromis le plus équilibré entre puissance et contrôle du risque.

Les différences entre algorithmes deviennent surtout visibles sur les bras faibles ou marginaux. Les signaux forts sont détectés rapidement par toutes les méthodes, tandis que seuls les algorithmes les plus adaptatifs parviennent encore à identifier une partie des petits effets avant l'horizon T .

Ces résultats confirment donc que l'intérêt principal des méthodes adaptatives est d'accélérer la découverte des signaux difficiles tout en conservant un contrôle raisonnable du FDR.

5.2. Résultat sur les données réelles

5.2.1. Présentation et analyse des jeux de données réelles

Nous évaluons les algorithmes sur quatre jeux de données réelles, résumés dans le tableau 14. Deux jeux sont continus : **Effort**, qui mesure une tâche d'effort réalisée par des travailleurs répartis en 60 groupes, et **Exercise**, qui étudie différentes politiques d'incitation à l'activité physique. Deux jeux sont binaires : **Penn** et **Walmart**, deux méga-études d'incitation à la vaccination. Dans Effort, le signe des observations est inversé afin que les bras positifs correspondent, comme dans nos algorithmes, à des moyennes supérieures au contrôle.

Voir Annexe G — Table 13

Avant d'appliquer les méthodes bandit, nous réalisons une analyse statistique classique : tests t pour les données continues, tests exacts de Fisher pour les données binaires, puis correction de Benjamini-Hochberg à $\text{FDR} \leq 5\%$. Cette analyse sert de référence empirique pour comparer les découvertes des algorithmes.

Les jeux de données présentent des profils très différents. Effort et Exercise contiennent de nombreux bras

significativement supérieurs au contrôle, ce qui en fait des cas favorables à la détection adaptative. Penn est beaucoup plus difficile : les effets sont faibles et un seul bras reste significatif après correction BH. Walmart, au contraire, dispose d'effectifs très élevés ; malgré des effets absolus modestes, presque tous les bras sont détectés comme significatifs.

5.2.2. Comparaison des quatre algorithmes

Les quatre algorithmes (JJ, V2, V3 et SR) sont comparés selon plusieurs critères : nombre de bras positifs découverts, vitesse de découverte d'un même ensemble de bras, et similarité de l'ordre de découverte via le tau de Kendall. L'objectif n'est donc pas seulement de mesurer combien de bras sont trouvés, mais aussi avec quel budget et avec quelle stabilité les algorithmes les identifient.

5.2.3. Comparaison des résultats des 4 algorithmes

Les 4 algorithmes que nous avons mis en places ont été testés sur les 4 jeux de données que nous disposons par rapport à différentes métriques telles que le nombre de positifs découverts, la vitesse de découvertes d'un même set de positifs et la corrélation entre les différentes listes trouvées à travers le tau de Kendall afin de vérifier la robustesse des résultats.

Nombre de positifs découverts

Comparaison des adaptatifs contre les uniformes Nous avons comparé pour chaque algorithme, l'évolution du nombre de bras positifs découverts par l'allocation adaptative et par l'allocation uniforme cyclique. On observe que les courbes adaptatives sont généralement au-dessus des courbes uniformes, ce qui confirme l'intérêt de l'allocation adaptative pour accélérer les découvertes. Les versions avec contrôle online restent en dessous des versions classiques, ce qui est attendu : estimer μ_0 pendant l'expérience ajoute une incertitude supplémentaire et ralentit les rejets. Les figures analogues pour les autres jeux de données sont présentées en annexe (18, 19, 20, 21).




Figure 5 – Nombre de positifs en fonction du temps pour les 4 jeux de données et les 4 algorithmes

Comparaison de JJ, V2, V3, et SR Pour comparer nos 4 algorithmes entre eux, nous ne gardons plus que les courbes adaptatif en mono-échantillon. Nous observons ainsi que V3 semble meilleur sur les jeux de données WALMART, EFFORT et EXERCISE. Pour PENN, c'est plutôt V2 qui semble meilleur, or cela correspondre à l'idée

que la normal-mixture est meilleur concernant les petits jeu de données car PENN est notre plus petit jeu de données binaires. Globalement l'ordre de performance est souvent $V3 > V2 > JJ > SR$.

Cependant cette metrique dispose d'un défaut à prendre en compte, les vrais positifs ne sont pas réellement connus et ne le seront jamais car nous avons des données réelles. Ainsi bien que ces graphiques soient pertinents pour appréhender le comportement des différentes situations testées entre elles, ils ne permettent pas de conclure à eux seuls.

Vitesse de découverte du même set de positifs

Le constat précédent nous a poussé à comparer les vitesses de découverte d'un même set entre les algorithmes. En effet cela nous permet de nous libérer de l'incertitude des vrai positifs.




Figure 6 – Différence de temps de découverte entre uniforme et adaptatif (uniforme - adaptatif)

Comparaison des adaptatifs contre les uniformes Ainsi cette heatmap nous montre l'écart de temps de découverte du plus grand set commun des différent algorithmes en prenant pour calcul temps de l'uniforme moins temps de l'adaptatif. On observe que toutes les cases sont positifs, dans toutes les situations l'adaptatifs trouve plus vite le même set que l'uniforme.




Figure 7 – Vitesse de découverte des même set en fonction des algorithmes et des jeux de données

Comparaison de JJ, V2, V3, et SR De même, la figure 9 montre les temps auxquels les différents algorithmes ont trouvé pour chaque jeu de données le plus grand set commun. Ainsi plus le temps est petit plus l'algorithme a trouvé vite et don plus il est performant. On observe ci ce qui se voyait déjà lors de l'analyse des courbes de nombre de positifs, V3 est meilleur pour les EFFORT, EXERCISE et WALMART et c'est V2 pour PENN, toujours globalement dans cette configuration : V3, V2, JJ, SR.

Robustesse des résultats

La dernière question qui se pose est la reproductibilité des résultats. Le but étant de vérifier si les algorithmes trouvent globalment les bras dans le même ordre ou non.

C'est pourquoi la figure 10 ci desous est pertinente, elle montre un exemple visuel de répartition des découvertes en fonction des moyennes empirique des bras. Nous avons en abscisse le temps de découverte des bras et en ordonnée la moyenne empirique. Ainsi plus un bras est haut plus sa moyenne empirique est haute et plus il devrait être découvert tôt et donc être à gauche. Or c'est bien cette tendance globale que l'on observe que ce soit dans le cas adaptatif (en vert) ou uniforme (en gris), et que ce soit dans le cas mono et bi-échantillon. Cependant il y a une certaine variation qui est clairement due au hasard du tirage de chaque bras.




Figure 8 – Moyenne empirique des bras en fonction de leur temps de découverte

Temps de découverte en fonction de la moyenne Dans les fait, les tableaux en annexe (figure 26, 27, 28, 29) montrent que les set ne sont presque jamais découverts dans le même ordre exacte. Cependant cela peut être normal si deux bras disposent de moyenne proches ils sont découverts parfois l'un avant l'autre. C'est pourquoi nous avons décidé d'utiliser le tau de Kendall en coefficient de corrélation afin de ne pas être restreint par des différences ponctuelles de découvertes et avoir ainsi une vision globale de la correspondance entre les rangs des découvertes par algorithme.




Figure 9 – Corrélation entre les sets de positifs découverts en fonction des algorithmes

Correlation entre les rang de découvertes des bras C'est ce qui est montré par la figure 11 qui donne une heatmap pour chaque jeu de donnée qui compare les rangs de découvertes de chaque algorithme. Ainsi nous avons calculé que les coefficients de corrélation disposent d'une valeur moyenne à 0.78 avec un minimum atteint à 0.51 pour EFFORT qui est un jeu de donnée particulier car certain bras sont très petits (5 données) et un maximum à 0.95 pour PENN. Globalement les algorithmes découvrent donc les bras dans un ordre similaire bien qu'il epeut y avoir des différences plus ou moins importantes en fonction du jeu de donnée.

Impact initialisation

Enfin il nous a semblé pertinent de tester l'impact d'une plus grande initilisation sur WALMART car le temps d'exécution était trop long pour le faire sur tout les jeux.

Walmart initialization grid - discovery curves
Uniform and Adaptive are compared in total experimental budget.




Figure 10 – Impact de l’initialisation sur l’allure des courbes de positif pour WALMART

La figure 12 montre donc l’allure des courbes du nombre de positifs en fonction du temps pour la version adaptatif et uniforme mono-échantillon. Il semble que les plus grandes initialisations n’aident par l’algorithme adaptatif à trouver plus vite les positifs, c’est en effet la courbe orange (plus petite initialisation) qui trouve tout les positifs en premier pour chaque algorithme.

6. Discussion et Limites

Les résultats confirment l’intérêt des méthodes adaptatives : à ensemble de bras découvert identique, elles atteignent généralement les découvertes plus tôt que l’allocation uniforme cyclique. L’apport principal n’est donc pas seulement le nombre final de bras détectés, mais surtout la réduction du budget nécessaire pour arriver au même ensemble de découvertes. Cet avantage dépend toutefois du cadre expérimental : il faut un rapport signal/bruit suffisant, un horizon assez long, et une phase d’initialisation minimale pour stabiliser les premières estimations. Lorsque les effets sont faibles, comme dans certains jeux de données réelles, le gain adaptatif devient naturellement plus limité.

Les algorithmes présentent aussi des compromis différents. JJ est le plus prudent, avec des découvertes plus lentes mais un comportement conservateur. V3 est plus agressif et détecte souvent plus vite, mais ses garanties sont plus fragiles dans les situations où le seuil de comparaison est estimé. V2, fondé sur la séquence Normal Mixture, apparaît comme le compromis le plus stable entre vitesse, puissance et validité statistique. SR reste utile comme point de comparaison, mais exploite moins finement le retour d’information adaptatif.

Sur données réelles, les vrais positifs ne sont pas connus. Les comparaisons avec l’analyse statistique classique doivent donc être interprétées comme une référence empirique, et non comme une vérité terrain. Le bootstrap permet de comparer les comportements algorithmiques sur les mêmes données, mais ne crée pas d’information nouvelle : il sert à stabiliser la comparaison des méthodes, pas à démontrer définitivement qu’un bras est causalement positif.

La principale limite théorique concerne le régime bi-échantillon avec contrôle online. Le théorème de Jamieson & Jain suppose un seuil μ_0 fixe et connu. Lorsque μ_0 est remplacé par une moyenne de contrôle estimée séquentiellement, la validité finite-sample n’est plus automatique : un estimateur ponctuel du contrôle peut être trop bas et casser la

propriété de sur-martingale sous H_0 . Le correctif retenu consiste donc à comparer les bras traitement à une borne supérieure de confiance du contrôle, et non à sa moyenne ponctuelle. Cette solution restaure une domination prudente, mais ralentit les découvertes, ce qui est cohérent avec l'incertitude supplémentaire introduite par le contrôle inconnu.

Enfin, ce travail met en évidence l'écart entre performance empirique et validité formelle. Les simulations montrent que les méthodes adaptatives peuvent être très efficaces, mais les garanties statistiques dépendent fortement de la construction des p-valeurs anytime ou des e-processus utilisés. Une extension naturelle serait de formuler plus systématiquement les procédures en termes d'e-valeurs, notamment pour mieux gérer la dépendance entre bras induite par un contrôle partagé et pour renforcer le traitement du cas continu à variance empirique.

7. Conclusion

Ce travail montre que les bandits adaptatifs permettent d'accélérer les tests multiples avec contrôle du FDR, en combinant allocation séquentielle, p-valeurs anytime et procédure BH. Nos implémentations de JJ, V2, V3 et SR montrent que l'adaptatif trouve généralement les mêmes bras positifs plus vite que l'uniforme, en simulation comme sur données réelles. V2 apparaît comme le compromis le plus robuste entre puissance, vitesse et validité, tandis que JJ est plus conservateur, V3 plus agressif et SR moins adaptatif. Ces résultats doivent rester prudents : sur données réelles, les vrais positifs ne sont pas connus et l'analyse classique n'est qu'une référence empirique. De plus, JJ avec variance empirique, le betting continu et le contrôle online présentent des limites théoriques finite-sample. Au final, l'approche est prometteuse pour les méga-études, mais nécessite de distinguer clairement performance pratique et garanties formelles.

Références

- [1] Jamieson, K. G., & Jain, L. (2019). *A Bandit Approach to Multiple Testing with False Discovery Control*. NeurIPS 2018. arXiv :1809.02235.
- [2] Benjamini, Y., & Hochberg, Y. (1995). *Controlling the false discovery rate : a practical and powerful approach to multiple testing*. J. Roy. Stat. Soc. B, 57(1), 289–300.
- [3] Howard, S. R., Ramdas, A., McAuliffe, J., & Sekhon, J. (2021). *Time-uniform, nonparametric, nonasymptotic confidence sequences*. Ann. Statist., 49(2), 1055–1080.
- [4] Welford, B. P. (1962). *Note on a method for calculating corrected sums of squares and products*. Technometrics, 4(3), 419–420.
- [5] Milkman, K. L. et al. (2021). *A megastudy of text-based nudges encouraging patients to get vaccinated*. PNAS, 118(20), e2101165118.
- [6] Milkman, K. L. et al. (2022). *A 680,000-person megastudy of nudges to encourage vaccination in pharmacies*. PNAS, 119(6), e2115126119.
- [7] Johari, R., Koomen, P., Pekelis, L., & Walsh, D. (2022). *Always valid inference : Continuous monitoring of A/B tests*. Operations Research, 70(3), 1806–1821.
- [8] Wang, R., & Ramdas, A. (2022). *False discovery rate control with e-values*. J. Roy. Stat. Soc. B, 84(3), 822–852.
- [9] Audibert, J.-Y., Bubeck, S., & Munos, R. (2010). *Best arm identification in multi-armed bandits*. COLT 2010.
- [10] Bowen, D., Green, E., & Simmons, J. (2022). *Making megastudies more effective*. Wharton School Preprint.
- [11] Ville, J. (1939). *Étude critique de la notion de collectif*. Gauthier-Villars, Paris.
- [12] Waudby-Smith, I., & Ramdas, A. (2023). *Estimating means of bounded random variables by betting*. J. Roy. Stat. Soc. B, 85(1), 1–27. arXiv :2010.09686.

A. Annexe - Simulateur interactif

Un simulateur interactif a été développé en Python (avec Streamlit) pour accompagner ce projet. Il permet de reproduire et d'explorer les expériences de la Section 4 : l'utilisateur configure les paramètres ($n, \delta, \sigma, \Delta$, horizon) via une interface graphique, lance les simulations et visualise en temps réel les courbes TPR, la répartition des tirages, les p-values anytime et les métriques FDR/TPR réels (ces dernières uniquement en simulation, la vérité terrain H_1 étant connue).

Lancer le simulateur localement :

```
git clone https://github.com/Chams22/bandit_approach_simulation
cd bandit_approach_simulation
pip install -r requirements.txt
streamlit run streamlit_visu/app_bandit.py
```

B. Annexe - Expérience 1




Figure 11 – Courbes TPR Adaptatif vs Uniforme pour différentes valeurs de δ ($\sigma = 0,5, \delta = 0,05, T = 800$).

C. Annexe - Expérience 2




Figure 12 – Courbes TPR Adaptatif vs Uniforme pour différentes valeurs de σ .

D. Annexe - Expérience 3




Figure 13 – Courbes TPR Adaptatif vs Uniforme pour les différentes configurations

E. Annexe - Expérience 4




Figure 14 – Courbes TPR Adaptatif vs Uniforme pour différentes valeurs de init_pulls ($\sigma = 0,5$, $\delta = 0,05$, $T = 800$).

F. Annexe - Expérience 5




Figure 15 – Courbes TPR Adaptatif vs Uniforme pour différentes proportions de vrais positifs .

G. Annexe - Statistiques classiques des jeux de données réelles

Paramètre	EFFORT	EXERCISE	PENN	WALMART
Nombre de bras	60	54	20	23
Type de données	Continues	Continues	Binaires	Binaires
Données/bras max	438	4606	2397	34623
Données/bras min	5	412	2295	27365
Moyenne max	-376.2	0.3241	0.467	0.3231
Moyenne min	-1525.5982	0.0703	0.4177	0.294
Variance max	992751.9053	1.7056	0.249	0.2187
Variance min	165500.7	1.1177	0.2433	0.2076

Table 14 – Caractéristiques des jeux de données utilisés





Figure 16 – Comparaison des bras traitements vs. contrôle — données *Effort* (test *t* + correction BH). Les barres vertes indiquent $q < 0,05$; les barres bleues une absence de significativité.

Figure 17 — Comparaison des bras traitements vs. contrôle — données *Exercice* (test t + correction BH).




Figure 18 – Comparaison des bras traitements vs. contrôle — données *Penn* (test de Fisher exact + correction BH). Seul le bras 5 (*Flu shot reserv*) est significatif ($q < 0,05$, *).




Figure 19 — Comparaison des bras traitements vs. contrôle — données *Walmart* (test de Fisher exact + correction BH). Quasi-totalité des bras significatifs ($q < 0,001$, ***).

H. Annexe - Résultats sur données réelles




Figure 20 – Nombre de positifs découverts en fonction du temps pour le jeu de données WALMART.




Figure 21 – Nombre de positifs découverts en fonction du temps pour le jeu de données EFFORT.




Figure 22 – Nombre de positifs découverts en fonction du temps pour le jeu de données EFFORT.




Figure 23 – Nombre de positifs découverts en fonction du temps pour le jeu de données EXERCISE.




Figure 24 – Nombre de positifs découverts en fonction du temps pour le jeu de données PENN.

EFFORT - temps de decouverte des memes sets entre algorithmes
 Une cellule remplie signifie que les deux algorithmes ont trouve le meme set a la taille k ; negatif signifie que B est plus rapide.




Figure 25 – Comparaison des set de découvertes EFFORT

EXERCISE - temps de decouverte des memes sets entre algorithmes
 Une cellule remplie signifie que les deux algorithmes ont trouve le meme set a la taille k ; negatif signifie que B est plus rapide.




Figure 26 – Comparaison des set de découvertes EXERCISE

PENN - temps de decouverte des memes sets entre algorithmes
 Une cellule remplie signifie que les deux algorithmes ont trouve le meme set a la taille k ; negatif signifie que B est plus rapide.




Figure 27 – Comparaison des set de découvertes PENN

WALMART - temps de decouverte des memes sets entre algorithmes
 Une cellule remplie signifie que les deux algorithmes ont trouve le meme set a la taille k ; negatif signifie que B est plus rapide.




Figure 28 – Comparaison des set de découvertes WALMART